Vom Prompt zum Beat: Evaluierung von Steuerungsmethoden zur automatisierten Generierung von Live-Coding-Code in Strudel CC

Exposé zur Bachelorarbeit

vorgelegt von

Marc Gusev

EDV.Nr.:916844

dem Fachbereich VI – Informatik und Medien
der Berliner Hochschule für Technik Berlin
vorgelegte Bachelorarbeit
zur Erlangung des akademischen Grades

Bachelor of Science (B.Sc.)

im Studiengang

Medieninformatik

Tag der Abgabe 28. Juli 2026

Betreuung
Prof. Dr. Siamak Haschemi Berliner Hochschule für Technik

BHT Berliner Hochschule für Technik

Studiere Zukunft

Einleitung

Motivation und Problemstellung

Sprachmodelle werden zunehmend eingesetzt, um Code in domänenspezifischen Sprachen zu erzeugen. Da ihre Ausgaben probabilistisch sind, eine ausführende Instanz aber strikt gültige Syntax verlangt, werden Steuerungsverfahren vorgeschaltet – etwa Constrained Decoding, grammatikgeführte Generierung oder erzwungene Ausgabeschemata. Diese Verfahren sind jedoch nicht kostenlos. Tam u. a. (2024) zeigen, dass die Reasoning-Fähigkeit unter Formatzwang deutlich zurückgeht und strengere Vorgaben zu größeren Einbußen führen. Park u. a. (2024) weisen nach, dass grammatikgeführte Verfahren die Wahrscheinlichkeitsverteilung des Modells verzerren, sodass Ausgaben zwar grammatikalisch korrekt sind, aber mit Wahrscheinlichkeiten auftreten, die nicht mehr denen des Modells entsprechen. Beide Befunde stammen aus Domänen mit eindeutig richtiger Zielausgabe. Für kreative domänenspezifische Sprachen, in denen es keine korrekte, sondern nur gültige und passende Ausgaben gibt, ist bislang offen, was Steuerung tatsächlich kostet.
Als Vorarbeit ist im Modul „Angewandte LLMs“ die Webanwendung *SemanticBeats* entstanden – ein rein clientseitiger Prototyp in JavaScript, der die Live-Coding-Umgebung Strudel CC (Roos und McLean, 2023) im Browser kapselt und als Sprachmodell ein lokal über Ollama betriebenes `qwen2.5:7b` anspricht. Ein Musikstück zerfällt architektonisch in fünf unabhängige Klangebenen; eine hartkodierte Sound-Library hält für jeden Klangbaustein eine eindeutige Kennung sowie semantische Schlagworte vor. Ein deterministischer Compiler setzt den Strudel-Ausdruck bei jeder Zustandsänderung neu zusammen, wobei das Sprachmodell ausschließlich Kennungen, Modifikatoren und Parameterwerte ausgibt und den ausführbaren Code zu keinem Zeitpunkt selbst schreibt.
Der Prototyp erfüllt seine Funktion, doch der Preis dieser Konstruktion ist unbeziffert. Weil das Modell nur aus einem kuratierten, geschlossenen Katalog wählen darf, ist die klangliche Ausdrucksbreite des Systems durch dessen Umfang gedeckelt; welchen Anteil an Vielfalt und an Übereinstimmung mit der geäußerten Nutzerabsicht diese Absicherung kostet, wurde nie gemessen. Damit steht der Prototyp stellvertretend für ein allgemeineres Problem: Netz u. a. (vgl. 2024, S. 7) halten für den Einsatz grammatikgeführter Verfahren auf domänenspezifische Sprachen ausdrücklich fest, dass ein systematischer Vergleich der Semantik gesteuerter und ungesteuerter Ausgaben noch aussteht. Hinzu kommt eine Randbedingung, die in der Literatur zu Steuerungsverfahren kaum berücksichtigt wird: Live Coding findet in Echtzeit statt, während jeder zusätzliche Steuerungsmechanismus Kontext und Verarbeitungskette verlängert. Die vorliegende Arbeit setzt an dieser Stelle an und beziffert den Zielkonflikt zwischen Verlässlichkeit, Ausdrucksbreite und Antwortzeit messend, statt ihn argumentativ zu behandeln.

Forschungsfrage

Die vorliegende Arbeit untersucht die folgende Forschungsfrage:

> *Wie wirken sich gestufte Steuerungsmechanismen eines „Kreativen Harness“ auf syntaktische Validität, semantische Treue, Ausgabediversität und Antwortlatenz eines lokal betriebenen 7B-Sprachmodells bei der Generierung von Strudel-CC-Code aus?*

Nach dem PICO-Modell strukturiert: *Population* ist die Generierung von Strudel-CC-Code durch ein lokales Sprachmodell (`qwen2.5:7b` über Ollama); *Intervention* sind vier aufeinander aufbauende Steuerungsstufen; *Comparison* ist das ungesteuerte Modell, das auf einen rohen Prompt unmittelbar Code ausgibt; *Outcome* sind vier getrennt erhobene Größen – Anteil fehlerfrei ausführbarer Ausdrücke, F1 der erzeugten gegenüber den geforderten Schlagworten, normalisierte Entropie über die Schlagwortmengen sowie Median und 95-Perzentil der Antwortlatenz.

Daraus ergeben sich folgende Unterfragen:

1. Welchen Beitrag leistet jede einzelne Steuerungsstufe zum Anteil fehlerfrei ausführbarer Ausdrücke, aufgeschlüsselt nach Syntaxfehlern, unbekannten Funktionen und nicht existierenden Klangbausteinen?
2. Erhöht semantisches Grounding die als F1-Wert gemessene Übereinstimmung zwischen den geforderten und den tatsächlich gelieferten Schlagworten gegenüber der vorhergehenden Stufe?
3. Lässt sich die normalisierte Entropie der Ausgaben über wiederholte Durchläufe desselben Prompts erhöhen, ohne den Anteil fehlerfrei ausführbarer Ausdrücke zu senken?
4. Welche Latenzkosten verursachen die Steuerungsmechanismen, und wo liegen Median und 95-Perzentil je Stufe innerhalb der von Miller (1968) benannten Grenzen von zwei beziehungsweise zehn Sekunden?

Vorgehensweise

Der folgende Abschnitt grenzt die verwendeten Begriffe ab, ordnet den Stand der Forschung zu Constrained Generation und Retrieval-Augmented Generation ein und beschreibt das Stufenmodell sowie das Evaluationsdesign, mit dem die vier Messgrößen erhoben werden. Abschließend werden der erwartete Beitrag der Arbeit und die bewusst ausgeklammerten Aspekte zusammengefasst.

Methodik

Stand der Forschung

Live Coding bezeichnet die Praxis, Musik durch das Schreiben und Verändern von Programmcode zur Laufzeit zu erzeugen. Strudel CC stellt dafür eine domänenspezifische Sprache im Browser bereit, die den Ansatz von TidalCycles nach JavaScript überträgt (Roos und McLean, 2023). Unter *Controlled Generation* beziehungsweise *Constrained Decoding* werden Verfahren zusammengefasst, die den Ausgaberaum eines Sprachmodells während der Generierung einschränken – durch Grammatiken, Ausgabeschemata oder eine Zwischendarstellung, die anschließend deterministisch übersetzt wird. *Retrieval-Augmented Generation* ergänzt den Prompt um abgerufenen Kontext; *GraphRAG* nutzt dafür einen Wissensgraphen und erschließt Kontext über Kanten transitiv statt allein über Ähnlichkeit.
Für Zielsprachen mit eindeutig richtiger Ausgabe – etwa SQL, JSON-Schemata oder API-Aufrufe – sind diese Verfahren gut untersucht, und ihre Kosten sind dokumentiert: Tam u. a. (2024) messen einen deutlichen Rückgang der Reasoning-Fähigkeit unter Formatzwang, Park u. a. (2024) beschreiben die Verzerrung der Modellverteilung durch grammatikgeführtes Decoding. Für domänenspezifische Sprachen liegen erste Arbeiten vor: Netz u. a. (vgl. 2024, S. 7) weisen für Grammar Masking einen Gewinn an syntaktischer Validität nach, halten jedoch ausdrücklich fest, dass eine systematische Untersuchung semantischer Unterschiede zwischen gesteuerten und ungesteuerten Ausgaben noch aussteht.
Daraus ergibt sich die Lücke, an der diese Arbeit ansetzt, in drei Punkten. *Erstens* unterscheidet sich eine kreative domänenspezifische Sprache grundlegend von den bisher untersuchten Zielsprachen: Es gibt keine korrekte Ausgabe, sondern nur gültige und zur Absicht passende. *Zweitens* wird der Verlust an Vielfalt bislang theoretisch als Verteilungsverzerrung beschrieben (Park u. a., 2024) und für Aufgabengenauigkeit gemessen (Tam u. a., 2024), nicht jedoch als Ausgabediversität erhoben – und schon gar nicht gemeinsam mit semantischer Treue und Antwortzeit an derselben Pipeline. *Drittens* messen die genannten Arbeiten große, entfernt

betriebene Modelle ohne Latenzbudget. Antwortzeit ist für interaktive Systeme jedoch folgenreich: Schon 500 Millisekunden mehr je Operation senken Interaktionsrate und Hypothesenbildung (vgl. Liu und Heer, 2014, S. 2122). Sie ist zugleich keine Größe, die ohne Begründung zu minimieren wäre – in einem Experiment mit 240 Teilnehmenden galten Ausgaben nach zwei Sekunden als weniger durchdacht als nach neun oder zwanzig (vgl. Tan u. a., 2026, S. 1).

Untersuchungsansatz

Stufenmodell. Anstelle einer vollständigen Ablationsstudie über alle Kombinationen wird ein inkrementelles Stacking gewählt: Jede Stufe enthält alle vorhergehenden und ergänzt genau einen Mechanismus. Das hält den Versuchsraum erhebbar und macht jede Veränderung einer Messgröße eindeutig dem zuletzt hinzugefügten Mechanismus zurechenbar.

Stufe	Mechanismus	Erwartete Wirkung
S0	Baseline: roher Prompt, direkte Codeausgabe	Referenzpunkt ohne Steuerung
S1	Tag-basiertes Grounding: nur passende Kennungen im Systemprompt	schließt erfundene Klangbausteine aus
S2	Zwischendarstellung in JSON, deterministische Kompilierung	Syntaxfehler gegen null
S3	Musikalische Chain-of-Thought	höhere musikalische Kohärenz
S4	GraphRAG über einen kuratierten Wissensgraphen	höhere semantische Treue bei Prompts ohne direkten Schlagworttreffer

Die Stufen S1 und S2 sind im bestehenden Prototyp bereits implementiert. Die Arbeit setzt ihre Wirksamkeit deshalb nicht voraus, sondern ordnet sie erstmals gegenüber der ungesteuerten Baseline ein – mit dem methodischen Vorteil, dass die Messinfrastruktur gegen ein real laufendes System entwickelt werden kann. Der Graph in Stufe S4 wird bewusst klein und kuratiert gehalten und umfasst nur die Kanten Genre ↔ Tempo ↔ Klangbaustein ↔ Strudel-Funktion; das hält den Konfigurationsraum klein und die Ergebnisse interpretierbar.

Versuchsträger und Konstanthaltung. Modellversion (`qwen2.5:7b`), Hardware und Temperatur bleiben über alle Durchläufe konstant und werden dokumentiert, damit die gemessenen Effekte allein den Steuerungsmechanismen zuzurechnen sind. Die Temperatur wird dabei auf einen Wert oberhalb von null festgelegt und der Zufallskeim je Wiederholung variiert; andernfalls lieferte derselbe Prompt identische Ausgaben und die Diversitätsachse wäre konstruktionsbedingt null. Die verwendeten Keime werden protokolliert, sodass die Durchläufe trotz Variation reproduzierbar bleiben.

Datengrundlage. Der Promptkorpus umfasst 40 selbst erstellte Eingaben in vier Kategorien zu je zehn: mit direktem Treffer im Schlagwortvokabular, als Genreanfrage ohne solchen Treffer (prüft gezielt Stufe S4), als Struktur- oder Mehrkanalanfrage sowie bewusst unterspezifiziert. Jede Stufe wird über jeden Prompt zehnmal ausgeführt, woraus 2 000 Durchläufe je Messlauf entstehen. Die erwartete Schlagwortmenge je Prompt wird vorab festgelegt und vor dem ersten Messlauf eingefroren, damit Erwartungen nicht nachträglich an die Ergebnisse angepasst werden können; die Annotation erfolgt in zwei zeitlich getrennten Durchgängen, deren Übereinstimmung berichtet wird.

Metriken. Erhoben werden vier getrennte Größen; eine Zusammenfassung zu einer einzigen Kennzahl unterbliebe bewusst, weil sich die Effekte der Mechanismen sonst gegenseitig verdecken würden.

- **Syntaktische Validität.** Anteil der Ausdrücke, die sich ohne Fehler übersetzen und über einen Takt abfragen lassen, erhoben ohne Audioausgabe und aufgeschlüsselt nach Syntaxfehler, unbekannter Funktion und nicht existierendem Klangbaustein. Nur so wird

sichtbar, welche Stufe welche Fehlerklasse beseitigt; die dritte bricht die Ausführung nicht ab und bliebe in einer Sammelquote unsichtbar.

- **Semantische Treue.** Precision, Recall und F1 der gelieferten gegenüber den geforderten Schlagworten. Damit die Größe auch für die Baseline gilt, die keine Kennungen ausgibt, werden alle Ausgaben über ein eigens erstelltes Lexikon auf dasselbe Vokabular abgebildet: bei S0 und S1 aus dem erzeugten Code, ab S2 aus der Kennung. Erfundene Klangbausteine lösen zu keinem Schlagwort auf und senken die Precision.

- **Diversität.** Normalisierte Shannon-Entropie über die Schlagwortmengen wiederholter Durchläufe, nur über gültige Ausgaben. Ein bloßer Anteil verschiedener Ergebnisse begünstigte ungesteuerten, fehlerhaften Code und bildete die Schieflage einer Verteilung nicht ab; er wird nur ergänzend berichtet.

- **Antwortzeit und Aufwand.** Median und 95-Perzentil der Latenz sowie Umfang der Prompt- und Ausgabe-Token je Stufe.

Auswertung. Berichtet werden Median und Bootstrap-Konfidenzintervall je Stufe und Metrik. Ein Unterschied zwischen zwei benachbarten Stufen gilt als substanziell, wenn das Intervall die Null ausschließt und zugleich eine vorab festgelegte Relevanzschwelle überschritten wird; diese Schwellen sind gesetzt und nicht aus Daten abgeleitet, was bei der Interpretation kenntlich gemacht wird. Die Antwortzeit wird nicht als bestanden oder nicht bestanden gewertet, sondern in die belegten Grenzen von zwei und zehn Sekunden eingeordnet (vgl. Miller, 1968, S. 269 und S. 273). Für sich genommen wäre sie ohne Aussagekraft, da die ungesteuerte Baseline stets am schnellsten und zugleich am unbrauchbarsten ist. Erst im Verbund mit den drei übrigen Achsen entsteht die eigentliche Aussage der Arbeit: eine Nutzen-Kosten-Betrachtung über die Stufen und daraus eine begründete Empfehlung, welcher Grad an Steuerung für ein Werkzeug mit Echtzeitanspruch angemessen ist. Alle vier Größen sind vollautomatisch und ohne Probanden erhebbar.

Erwarteter Beitrag

Die Arbeit liefert für eine kreative domänenspezifische Sprache erstmals Messwerte dazu, was Steuerung kostet und was sie einbringt, und schließt damit für einen konkreten Fall die von Netz u. a. (vgl. 2024, S. 7) benannte Lücke: den systematischen Vergleich gesteuerter und ungesteuerter Ausgaben. Anders als in den bisher untersuchten Zielsprachen wird dabei nicht nur die Genauigkeit betrachtet, sondern zugleich die Vielfalt – jene Größe, deren Verlust unter Steuerung bislang theoretisch beschrieben (Park u. a., 2024), aber nicht erhoben wurde.
Als methodischer Beitrag entsteht die Abbildung der erzeugten Ausdrücke auf ein gemeinsames Schlagwortvokabular. Sie macht semantische Treue über alle Stufen vergleichbar, auch für die Baseline ohne Kennungen, und lässt sich auf andere domänenspezifische Sprachen mit annotiertem Bausteinkatalog übertragen. Messinfrastruktur, Promptkorpus und Referenzdatensatz werden offengelegt.
Praktisch richtet sich die Arbeit an alle, die Sprachmodelle in interaktive kreative Werkzeuge einbinden: An die Stelle der Faustregel, das Modell so weit wie möglich einzuschränken, tritt eine auf gemessene Kosten gestützte Empfehlung. Die Untersuchung kommt ohne Probanden und ohne personenbezogene Daten aus; da das Modell lokal läuft, verlassen die Eingaben das System nicht, und die Messungen bleiben offline durchführbar und reproduzierbar.

Abgrenzung und Ausblick

Vier Aspekte werden bewusst ausgeklammert.

Erstens wird grammatikgeführtes Decoding weder implementiert noch gemessen, sondern nur eingeordnet. Die Zwischendarstellung in Stufe S2 adressiert dieselbe Fehlerklasse, und eine parallele Evaluation beider Verfahren würde den Rahmen überschreiten. Der Ansatz bleibt jedoch die naheliegendste Fortsetzung: Verfahren, die die Verzerrung der Modellverteilung gezielt ausgleichen (Park u. a., 2024), könnten die hier gemessenen Diversitätskosten verringern – eine Frage, die sich mit der aufgebauten Messinfrastruktur unmittelbar anschließen ließe.
Zweitens findet keine Nutzerstudie statt; musikalische Qualität und ästhetische Wirkung werden nicht bewertet, da hierfür kein objektivierbarer Maßstab vorliegt.
Drittens werden weder Modelle verglichen noch wird ein Finetuning vorgenommen. Das Modell bleibt über alle Stufen unverändert, damit die gemessenen Effekte eindeutig den Steuerungsmechanismen zurechenbar bleiben.
Viertens gelten die Ergebnisse zunächst für genau eine Konstellation: ein Modell, einen kuratierten Klangkatalog und ein musikalisches Genre. Wie weit sie sich übertragen lassen, ist eine offene Frage, die die Arbeit benennt, aber nicht beantwortet. Hinzu kommt, dass sowohl das Schlagwortvokabular als auch der Referenzdatensatz vom Autor gesetzt sind; beide werden vollständig dokumentiert und ihre Grenzen in der Diskussion offengelegt.

Literaturverzeichnis

[Liu und Heer 2014] Liu, Zhicheng ; Heer, Jeffrey: The Effects of Interactive Latency on Exploratory Visual Analysis. In: *IEEE Transactions on Visualization and Computer Graphics* 20 (2014), Nr. 12, S. 2122–2131

[Miller 1968] Miller, Robert B.: Response Time in Man-Computer Conversational Transactions. In: *Proceedings of the December 9–11, 1968, Fall Joint Computer Conference, Part I (AFIPS '68)*. New York, NY, USA : ACM, 1968, S. 267–277

[Netz u. a. 2024] Netz, Lukas ; Reimer, Jan ; Rumpe, Bernhard: Using Grammar Masking to Ensure Syntactic Validity in LLM-based Modeling Tasks. In: *MODELS '24 Companion / Workshop Proceedings*. Aachen, Germany : ACM, 2024. – Preprint: arxiv.org/abs/2407.06146

[Park u. a. 2024] Park, Kanghee ; Wang, Jiayu ; Berg-Kirkpatrick, Taylor ; Polikarpova, Nadia ; D'Antoni, Loris: Grammar-Aligned Decoding. In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*, 2024

[Roos und McLean 2023] Roos, Felix ; McLean, Alex: Strudel: Live Coding Patterns on the Web. In: *Proceedings of the 7th International Conference on Live Coding (ICLC 2023)*. Utrecht, Netherlands : Zenodo, 2023

[Tam u. a. 2024] Tam, Zhi R. ; Wu, Cheng-Kuang ; Tsai, Yi-Lin ; Lin, Chieh-Yen ; Lee, Hung-yi ; Chen, Yun-Nung: Let Me Speak Freely? A Study on the Impact of Format Restrictions on Performance of Large Language Models. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track*, Association for Computational Linguistics, 2024. – aclanthology.org/2024.emnlp-industry.91

[Tan u. a. 2026] Tan, Felicia Fang-Yi ; Messerschmidt, Moritz A. ; Yin, Wen ; Nov, Oded: The Impact of Response Latency and Task Type on Human-LLM Interaction and Perception. In: *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems (CHI '26)*. New York, NY, USA : ACM, 2026. – Preprint: arxiv.org/abs/2604.06183